

专家方法论报告：利用高光谱成像和针对小样本集 ($N \approx 100$) 的高级建模方法预测花椒 (*Zanthoxylum*) 的挥发油含量

摘要

本报告旨在为利用高光谱成像 (HSI) 技术预测花椒 (*Zanthoxylum*) 挥发油含量的项目提供一个详尽的方法论指南。项目的核心挑战在于样本量有限 ($N \approx 100$)，而高光谱数据具有高维度特性 (即变量 P 远大于样本 N ，构成“ $N < P$ ”问题)。本报告首先阐述了一个关键的数据处理流程，该流程将原始的3D高光谱数据立方体通过严格的辐射定标、感兴趣区域 (ROI) 分割和光谱平均，转换为1D光谱特征向量。这一降维步骤是成功建模的基础。随后，报告详细评估了两条主要的建模路径。第一条是传统化学计量学路径，鉴于其在小样本集上的鲁棒性和已验证的成功先例 (例如，相关研究中PLSR模型在类似数据集上实现了 $R^2_p = 0.973$ 的预测精度)¹，本报告将其列为首选方案，重点推荐使用结合遗传算法 (GA) 的偏最小二乘回归 (GA-PLSR)²。第二条是深度学习路径，报告批判性地排除了数据需求量大的3D-CNN模型²，转而推荐适用于1D光谱数据的轻量级 (如1D-CNN²) 和混合 (如SAE-SVR²) 架构。最终建议是：采用GA-PLSR作为主要建模策略，以其鲁棒性、可解释性和已被证实的有效性确保项目成功；同时，将SAE-SVR (堆叠自编码器-支持向量回归) 作为次要探索路径，以捕捉传统线性方法可能忽略的复杂非线性特征。

第1部分：高光谱数据处理流程的分析与标准化

成功的模型建立在正确且可复现的数据处理之上。在此阶段的任何偏差都将导致后续所有建模工作的失效。您所提供的文件 (Image 2, ²) 证实了您拥有构建模型所需的全部数据：高光谱数据立方体 (X变量) 和对应的化学测量值 (Y变量)。

1.1 解读您的花椒高光谱数据结构

您提供的文件(如Image 2所示)构成了一个完整的HSI采集数据集, 包含了0165_11号样本的以下文件:

- REFLECTANCE_0165_11.dat (或 .raw 文件): 这是原始的高光谱数据立方体(Hypercube), 一个三维(x, y, λ)数组, 包含了样本的原始空间和光谱信息。
- 0165_11.hdr: 这是至关重要的头文件(**Header File**)。它是一个文本文件, 描述了 .dat 文件的元数据, 包括空间尺寸(如行、列)、波段数量, 以及最重要的——每个波段对应的具体波长(单位: nm)。
- DARKREF_...: 暗场参考文件(采集时镜头盖住)。
- WHITEREF_...: 白板参考文件(采集自高反射率的标准白板, 如99%反射率的Teflon板)。

拥有暗场和白场参考文件是确保科学准确性的必要条件。原始HSI数据是以“数字序号”(Digital Numbers, DN_s)记录的, 这一数值会受到相机暗电流、光源不均和曝光时间的影响。直接使用DN_s值建模, 将使模型不具备在新数据上的迁移能力。因此, 必须将DN_s值转换为物理意义上的反射率(**Reflectance**)。

行动步骤1: 辐射定标(黑白校正)

必须使用您提供的参考文件, 对每一幅原始图像(.dat)进行辐射定标。标准校正公式如下 2:

$$R_{ref} = \frac{R_{raw} - R_{dark}}{R_{white} - R_{dark}}$$

其中:

- R_{ref} : 校正后的反射率立方体(您后续建模所需的“X”数据)。
- R_{raw} : 原始样本立方体(例如 REFLECTANCE_0165_11.dat)。
- R_{dark} : 暗场参考图像(DARKREF_... 文件, 通常建议使用多次采集的平均值)。
- R_{white} : 白板参考图像(WHITEREF_... 文件, 同样建议使用平均值)。

这个逐像素的计算过程, 能有效去除暗电流噪声并校正光源在空间和光谱维度的不均匀性, 将数据从任意的DN_s单位转换为0到1(或0%到100%)范围内的标准反射率。

1.2 建立分析目标‘Y’(挥发油含量)

您的 .xls 文件(以 ² 和 ² 的.csv 格式提供)是模型的“真值”(Y变量, 即目标变量)。它们将HSI文件ID与化学测量值关联起来。基于 ² 的数据, 这种关联是明确的。

关键步骤: 建立数据字典和X-Y配对图

为了确保项目组织清晰, 必须明确记录您的数据, 如下表1所示。

表1: 数据字典与X-Y配对映射

样本ID (化学)	HSI文件ID (光谱)	挥发油含量	HSI原始文件 (X变
-----------	--------------	-------	-------------

		(ml/100g)	量)
YNTJ1-1#	O164-11	0.94215187	REFLECTANCE_0164_11.dat
YNTJ1-2#	O165-11	0.89285714	REFLECTANCE_0165_11.dat
YNTJ1-3#	O166-11	0.99641291	REFLECTANCE_0166_11.dat
YNZYJ1#	O152-11	2.39130435	(文件名待确认)
YNZYJ2#	O153-11	2.34278668	(文件名待确认)
... (以此类推, 完成所有约100个样本)	...	...	...

2

此表格是您后续自动化数据处理循环(例如Python脚本)的输入文件, 并能立即识别任何缺失的数据。

1.3 数据降维(一): 空间分割(ROI提取)

您的校正后图像(如Image 1所示)同时包含了花椒颗粒和深色背景。如果将背景(反射率接近0)纳入模型, 将引入大量与化学成分无关的噪声, 严重干扰模型性能。因此, 必须创建“掩膜”(Mask)以仅分离出属于花椒颗粒的像素。这个过程称为感兴趣区域(Region of Interest, ROI)提取。

推荐方法²:

1. 波段选择: 从HSI立方体中选择一个对花椒颗粒和背景具有高对比度的单波段图像(例如, Image 1中的绿色波段或近红外波段)。
2. 阈值分割: 使用自动阈值算法, 如 **Otsu**方法(在²中用于背景去除)², 生成二值化掩膜(1 = 花椒, 0 = 背景)。
3. 形态学清理: 使用形态学算法(如“开”运算和“闭”运算)², 去除孤立的噪声像素并填充花椒颗粒内部的空洞, 使掩膜更干净。

1.4 数据降维(二):从3D到1D的关键转变(提取平均光谱)

这是您项目中最关键的决策点:是使用整个3D HSI立方体(空间+光谱)还是仅使用1D光谱数据进行建模?

答案基于以下分析:

1. 目标 (**Y**) 是“体相”属性:您预测的是 ml/100g², 这是整个样本(Image 1中所有花椒颗粒)的平均化学属性, 而不是单个像素或单个颗粒的空间分布。
2. 样本 (**X**) 是异质的:您的样本(Image 1)是大量颗粒的异质堆积。
3. **3D**模型的局限性:一个3D-CNN模型(如²中用于花生仁的模型)试图学习空间模式(例如,“花生的边缘”与“油含量”相关)²。对于您这种“体相-对-体相”的预测问题, 这种空间信息是无关的, 甚至是误导性的。

因此, 对于您的“体相”预测任务, 最具统计代表性的光谱特征是所有花椒像素(即ROI区域内)的平均光谱(**Average Spectrum**)。这种方法在²(计算ROI中光谱的平均值)和²(使用整个叶片作为ROI获取平均光谱信息)中得到了应用, 是处理此类问题的标准方法。

行动步骤2:1D光谱提取

1. 对于每个校正后的HSI立方体(R_{ref})。
2. 应用1.3中生成的掩膜($M_{i,j}$)。
3. 对每个波长(λ_k), 计算掩膜区域($M_{i,j}=1$)内所有像素的反射率平均值。
4. 结果:每个样本(每张HSI图像)被转换为一个**1D**光谱向量。

您的数据集由此发生转变:

~100 (样本) x 600 (行) x 500 (列) x 200 (波段)

$\downarrow$

~100 (样本) x 200 (波段)

这个转变极大地简化了问题, 使其在 $N \approx 100$ 的样本量下变得可控。您现在面对的是一个经典的高维化学计量学问题。

1.5 光谱预处理:增强化学信号

提取的1D光谱仍会受到物理噪声的干扰, 如颗粒大小不均、堆积紧密度的差异(导致光散射)以及仪器基线漂移。必须通过预处理来最小化这些噪声, 凸显与挥发油含量相关的化学吸收信息。

标准预处理方法：

1. 散射校正：
 - 标准正态变量变换 (SNV): 对每个独立的光谱进行中心化和缩放 (均值为0, 标准差为1)。此方法在²和²中被用于处理光谱数据。
 - 多元散射校正 (MSC): 根据一个“理想”的平均光谱来校正每个光谱的散射。²和²中均提到了此方法。
2. 基线与分辨率增强：
 - Savitzky-Golay (SG) 导数: 通常使用一阶或二阶导数来消除基线漂移并分离重叠的吸收峰。²中提到了SG平滑。

推荐流程: 尝试多种预处理组合 (例如: 原始光谱、SNV、MSC、SNV+SG一阶导数), 并通过后续的交叉验证 (Cross-Validation) 来评估哪种组合能提供最佳的模型性能。SNV通常是一个优秀的起点²。

第2部分: 路径1: 传统化学计量学建模 (稳健的基线方案)

鉴于您的样本量 ($N \approx 100$), 化学计量学方法不仅不是“过时”的选择, 反而是黄金标准, 并且最有可能成为您项目的最佳解决方案。

2.1 核心挑战: “维度灾难” ($N < P$)

您的问题的核心是“ $N < P$ ”: 您的样本量 $N \approx 100$, 但您的变量 (波长) P 可能超过200 (具体取决于您的.hdr文件)。在这种情况下, 标准的多元线性回归 (MLR) 将灾难性地失败, 模型会完美地拟合数据中的噪声 (即过拟合), 导致其在预测新样本时毫无价值。

您必须使用专为 $N < P$ 问题设计的算法, 这些算法主要通过两种途径解决该问题:

1. 潜变量投影 (如 PLSR)。
2. 变量 (波长) 选择 (如 SPA, GA)。

2.2 潜变量回归 (全光谱建模)

偏最小二乘回归 (Partial Least Squares Regression, PLSR)

- 为何选择:这是解决 $N < P$ 问题的首选和最广泛使用的化学计量学方法。它被明确用于油含量预测², 并且在多项花椒(*Zanthoxylum*)品质研究中被提及¹。
- 工作原理:PLSR不会直接在200多个波长上建模, 而是将这些波长投影(压缩)到少数几个(例如5-15个)“潜变量”(Latent Variables, LVs)上。这些LVs的构建旨在最大化解释光谱(X)和挥发油含量(Y)之间协方差的能力。
- 关键证据:一项针对花椒(Sichuan pepper)的研究($N=118$, 与您的 $N \approx 100$ 非常接近)使用近红外光谱(NIRS, 即1D光谱)和PLSR来预测挥发油含量, 获得了极高的预测精度: $R^2_p = 0.973$ (预测集决定系数), $RMSEP = 0.272$ (预测均方根误差)¹。这个发现是强有力的证据, 表明PLSR是解决您特定问题的、已被验证的高可行性方案。

2.3 非线性模型(增强灵活性)

PLSR是一种线性方法。如果光谱与挥发油含量之间的关系本质上是非线性的, 以下模型可能会表现更好:

- 支持向量回归 (**Support Vector Regression, SVR**):SVR(特别是使用径向基函数RBF核时)擅长捕捉复杂的非线性关系。²在其混合模型中就使用了SVR作为最终的回归器²。
- 随机森林 (**Random Forests, RF**):RF是一种集成学习方法, 对过拟合具有很强的抵抗力, 并且能很好地处理 $N < P$ 数据。²的研究发现RF在红茶发酵品质判别中表现最佳²。

2.4 通过波长选择进行数据降维

使用所有200多个波段可能引入噪声。如果只有10-15个波段是真正重要的(例如与油脂中的C-H键振动相关), 那么仅选择这些波段可以创建更简单、更快速、更稳健的模型。²中比较了七种不同的变量选择方法²。

推荐的变量选择算法(基于您参考的文献):

1. 连续投影算法 (**Successive Projections Algorithm, SPA**)²:一种快速选择低共线性变量集的算法。
2. 遗传算法 (**Genetic Algorithm, GA**)²:一种启发式搜索算法, 通过“进化”来寻找波长的最优组合。²的研究发现GA-PLSR是预测油茶籽含油率的最佳传统模型²。
3. 竞争性自适应重加权采样 (**CARS**)²:一种模拟“适者生存”的波长选择方法。

行动步骤3:传统建模 workflow

1. 建立基线:在预处理后的1D光谱数据(例如SNV处理后)上, 建立 **PLSR** 模型。
2. 非线性基线:建立 **SVR** 和 **RF** 模型。

3. 特征优选:应用 **GA**, **SPA**, 和 **CARS** 算法筛选特征波长子集。
4. 评估优化模型:建立 **GA-PLSR**, **SPA-PLSR**, **CARS-SVR** 等模型。
5. 比较:使用严格的交叉验证(见2.5)比较所有模型的 R^2 和RMSEP。

2.5 针对小样本的严格验证

对于 $N=100$ 的样本量,简单的80/20训练/测试集划分是极其危险的——模型性能将高度依赖于哪20个样本最终进入了测试集。

解决方案:交叉验证 (Cross-Validation, CV)

- **K-折交叉验证 (K-Fold CV)**: (例如 $K=10$)。将 $N=100$ 的数据集分为10“折”(每折10个样本)。在9折上训练,在剩余1折上测试。重复10次,直到每折都作过测试集。这是评估小样本模型性能的稳健标准。
- **留一法交叉验证 (Leave-One-Out CV, LOOCV)**: K-Fold的极端情况($K=N$)。在 $N-1$ (99)个样本上训练,在1个样本上测试。重复100次。计算成本高,但是对于极小的数据集,它提供了最稳定的误差估计。

评估指标:

- **R^2** (决定系数): 模型对Y变量方差的解释程度(越高越好)。
- **RMSE** (均方根误差): 模型的预测误差,单位与Y变量相同(ml/100g)(越低越好)。
- **RPD** (相对预测偏差): 标准差与RMSEP的比值。RPD > 2.0 通常被认为模型具有良好的预测能力⁵。

第3部分:路径2:深度学习方法(针对小样本数据的适配)

这是一条探索性路径。鉴于PLSR在¹中的巨大成功,深度学习(DL)可能并非必要,但它有潜力捕捉PLSR(线性方法)可能错过的复杂非线性模式。

3.1 为什么3D-CNN

2

²中提出的3D-WPCA-CNN模型是HSI分析的前沿架构,它直接读取3D(X, Y, λ)数据立方

体²。

然而, 对该研究的深入分析²表明:

1. 该模型用于训练的样本量(N)为 **1737** 个花生仁。
2. 该模型包含数百万个可训练参数。

对您项目的启示:

使用一个具有数百万参数的3D-CNN来训练N=100的样本集, 在统计上是不可能成功的。模型会立即且完全地过拟合——它会记住您那100个样本的光谱噪声, 但对任何新样本的预测能力都为零。

结论: 必须放弃3D-CNN路径。所有可行的DL策略都必须基于我们在第1.4节中提取的**1D**光谱数据。

3.2 可行DL策略1: 基于1D平均光谱的1D-CNN

- 概念: 将您的1D平均光谱(例如 1x200 向量)视为一个序列, 类似于时间序列或音频信号。1D-CNN² 擅长在序列中寻找局部模式(例如, “1200nm处的峰值后紧跟1250nm处的谷值”), 并将这些模式与挥发油含量相关联。
- 架构: 一个简单的1D-CNN模型应包含:
 - Input (BatchSize, 200, 1)
 - Conv1D (例如 16 个滤波器, 核大小 5) $\rightarrow$ ReLU $\rightarrow$ MaxPooling1D
 - Conv1D (例如 32 个滤波器, 核大小 3) $\rightarrow$ ReLU $\rightarrow$ MaxPooling1D
 - Flatten
 - Dropout (例如 0.5) $\leftarrow$ (这是对抗**N=100**过拟合的关键层)
 - Dense (例如 20 个神经元) $\rightarrow$ ReLU
 - Dense (1 个神经元, 线性激活) $\rightarrow$ (挥发油含量预测值)
- 挑战: 即使是这种简单模型, 在N=100时仍极易过拟合。必须使用高比例的Dropout和数据增强(见3.5)。

3.3 可行DL策略2: 基于重塑光谱的2D-CNN

- 概念: 这是²中使用的一个巧妙技巧²。将1D光谱向量(例如 1x256 波段)重塑为一个2D“图像”(例如 16x16 像素)。
- 为何如此: 这允许使用标准的2D-CNN(非常擅长寻找空间模式)来搜索光谱“图像”中的“纹理”。2D卷积核可以同时“看到”(例如)波段1-3和波段17-19, 从而可能捕捉到1D-CNN忽略的复杂跨波段相关性。

- 结果:²发现, 对于他们的分类问题, 2D-CNN的效果优于1D-CNN²。

3.4 可行DL策略3(最推荐的DL方法): 混合SAE-SVR模型

- 概念:²中采用的这种混合方法², 非常适合处理您这种“ $N < P$ ”的小样本数据。它将DL的非线性特征提取能力与传统机器学习的稳健性结合起来。
- 阶段1: 无监督深度特征提取 (SAE)
 1. 输入: 仅使用您的1D光谱数据(X矩阵, $N=100 \times P=200$)。暂时忽略挥发油含量(Y变量)。
 2. 构建: 一个堆叠自编码器 (Stacked Autoencoder, SAE)。这是一个深度神经网络, 其训练目标是使其输出(重建光谱) 尽可能接近其输入(原始光谱)。
 3. 架构: $\text{Input (1x200)} \rightarrow \text{Encoder Hidden 1 (1x100)} \rightarrow \text{Code Layer (1x10)} \rightarrow \text{Decoder Hidden 1 (1x100)} \rightarrow \text{Output (1x200)}$ 。
 4. 训练: 训练网络, 使 $\text{Output} \approx \text{Input}$ 。
- 阶段2: 提取深度特征
 1. 训练完成后, 丢弃网络的后半部分(解码器)。
 2. 将您的100个光谱数据输入到前半部分(编码器), 并从最中间的“Code Layer”提取激活值。
 3. 结果: 您的数据集被非线性地降维:
 $\sim 100 (\text{样本}) \times 200 (\text{波段}) \rightarrow \sim 100 (\text{样本}) \times 10 (\text{深度特征})$
- 阶段3: 有监督回归 (SVR)
 1. 您现在面对的是一个“ $N > P$ ” ($100 > 10$) 的低维问题。
 2. 在这个100x10的数据集上训练一个SVR(如²所用)或PLSR, 来预测挥发油含量。

为何此方法有效: SAE阶段以无监督的方式利用数据(不看Y), 避免了对Y的过拟合, 它只是学习光谱数据本身的内在结构。随后的SVR阶段是一个简单、稳健的回归器, 非常适合 $N=100$ 的小样本量。这是将“深度学习”应用于您问题的最智能、最安全的方式。

3.5 1D光谱的数据增强

$N=100$ 对于任何DL模型都是极小的。您可以通过人工生成“新”数据来扩充训练集。对于1D光谱, 常见技术包括:

- 添加噪声: 向每个光谱添加少量(例如均值为0, 标准差为0.01)的高斯噪声。
 - 缩放与漂移: 将光谱乘以一个小的随机因子(如0.98-1.02)或添加一个小的随机偏移量。
-

第4部分: 综合分析与最终方法建议

4.1 可行方法决策矩阵

下表2总结了针对您N≈100数据集的可行建模路径的优缺点。

表2: 建模路径决策矩阵 (N≈100)

方法论	参考文献	数据类型	潜在性能	N=100时鲁棒性	可解释性
GA-PLSR	¹	1D 平均光谱	极高 ¹	优秀	高 (可分析选定波段和载荷)
SVR	²	1D 平均光谱	中-高	高	低
RF	²	1D 平均光谱	中-高	高	中 (可分析特征重要性)
1D-CNN	²	1D 平均光谱	高 (潜力)	低-中 (过拟合风险高)	低 (黑盒)
SAE-SVR	²	1D 平均光谱	极高 (两全其美)	高	低
3D-CNN	²	3D HSI立方体	(不适用)	极低 (注定失败)	(不适用)

4.2 深度分析与逻辑推演

1. 您的首要任务是获得一个准确、稳健的预测模型。
2. 外部研究¹已经使用标准化学计量学方法 (PLSR) 在一个几乎完全相同的问题上 (N=118, 花椒挥发油) 取得了近乎完美的 $R^2_p = 0.973$ 的结果。
3. 这一事实极大地降低了您的项目风险。您的任务已从“寻找一种新方法”转变为“应用一种已被验证的方法”。
4. 因此, 第2部分的传统化学计量学路径是您最安全、最快、最稳健的成功之路。
5. PLSR方法具有高度可解释性。您将能够报告哪些波长(例如与油脂中C-H基团相关的波长)对模型贡献最大, 从而提供化学见解。
6. 第3部分的深度学习路径是探索性的。其中, SAE-SVR² 是最有前途的, 因为它通过将无监督特征学习与有监督回归分离, 明确地设计用来处理小N数据。

4.3 最终行动方案建议

建议采取双轨策略: 一个主路径用于确保获得稳健、可发表的模型, 一个次路径用于探索潜在的性能上限。

1. 主要路径 (最高成功概率): GA-PLSR

1. 严格执行第1部分所述的数据处理流程(定标 $\rightarrow$ ROI $\rightarrow$ 1D平均光谱)。
2. 使用 SNV 对1D光谱进行预处理²。
3. 应用 GA-PLSR 模型², 该模型能同时优化潜变量数量和所选波长。
4. 使用严格的 10-折交叉验证 (10-Fold CV) 来评估模型性能。
5. 预期结果: 基于¹的先例, 预期可获得一个高精度模型 ($R^2 > 0.85-0.90$)。

2. 次要路径 (最佳DL探索): SAE-SVR

1. 使用与主路径相同的、经SNV预处理的1D光谱数据。
2. 实施第3.4节中详述的 SAE-SVR 混合架构²。
3. 构建一个SAE, 将您的 ~200+ 个波段压缩至 ~10-15 个深度特征。
4. 在这些低维特征上训练一个 SVR。
5. 使用 10-折交叉验证 进行评估。

最终结论:

应首先实施 GA-PLSR 路径。鉴于您的样本量 (N≈100), 它是最合适的方法, 其有效性在您特定的应用场景(花椒挥发油)中已得到证实¹, 且具有可解释性。

如果此模型未能达到所需的精度(例如 $R^2_{cv} < 0.8$), 则应启动次要路径, 部署 SAE-SVR 混合模型。这是最有希望捕捉复杂非线性关系, 同时又不会在N=100的数据集上过拟合的深度学习策略。

强烈建议: 不要在3D-CNN架构上投入时间², 因为对于您当前的样本量, 该路径在统计上是不可

行的。

Works cited

1. 花椒挥发油含量的近红外光谱无损检测 - 农业机械学报, accessed November 18, 2025, http://www.j-csam.org/jcsam/article/html/080320?st=article_issue
2. 基于高光谱成像的油茶籽含油率检测方法_周宏平.pdf
3. Rapid and Nondestructive Determination of origin, volatile oil, sanshoamides and crack rate in the 'Sichuan Pepper' Based on a Novel Portable Near Infrared Spectrometer - AGRIS, accessed November 18, 2025, <https://agris.fao.org/search/en/providers/122535/records/65df606b0f3e94b9e5d7dd42>
4. Characterization of Volatile Compounds and Odorants in Different Sichuan Pepper Varieties in Tallow Hotpot - PMC - PubMed Central, accessed November 18, 2025, <https://pmc.ncbi.nlm.nih.gov/articles/PMC11854310/>
5. Prediction of chemical indicators for quality of Zanthoxylum spices from multi-regions using hyperspectral imaging combined with chemometrics - Frontiers, accessed November 18, 2025, <https://www.frontiersin.org/journals/sustainable-food-systems/articles/10.3389/fsufs.2022.1036892/full>