花椒含油率模型实验进展报告-20260505

1. 阶段结论

当前数据集共 `197` 个样本，其中 Train `157` 个、Val `40` 个，光谱波段 `224` 个。上一阶段最优方案为：

- `SG一阶导(window=13) + GA + PLSR` 双模型融合
- 上一阶段正式验证结果：`Val R^2 = 0.8221`，`Val RMSE = 0.1901`，`Val MAE = 0.1632`

本轮在排除 `distill_ml`、`oil_ml_per_gram`、`oil_ml_per_100g` 等目标相关字段后，当前最优方案更新为：

- `SNV + SG一阶导(window=13, polyorder=2) + PLSR(10) + batch/quality特征 + Huber回归`
- 本轮正式验证结果：`Val R^2 = 0.8502`，`Val RMSE = 0.1744`，`Val MAE = 0.1449`

与上一阶段最优方案相比，`Val R^2` 从 `0.8221` 提升到 `0.8502`，绝对提升 `+0.0281`，相对提升约 `3.4%`；`Val RMSE` 从 `0.1901` 降到 `0.1744`，绝对下降 `0.0157`，下降约 `8.2%`；`Val MAE` 从 `0.1632` 降到 `0.1449`，绝对下降 `0.0183`，下降约 `11.2%`。

若与初始正式模型相比，`Val R^2` 已从 `0.7227` 提升到 `0.8502`，绝对提升 `+0.1275`，相对提升约 `17.6%`；`Val RMSE` 从 `0.2373` 降到 `0.1744`，下降约 `26.5%`。

2. 关键进展

1. 完成 `SNV + SG一阶导 + PLS低维表征 + 稳健回归` 路线补充实验，本轮最佳模型达到 `Val R^2 = 0.8502`。
2. 模型输入继续排除含油率目标值及其直接派生字段，避免把实验室测量结果带入训练。
3. 本轮最佳方案引入批次类别与图像质量类特征，包括 `batch one-hot`、`coverage_ratio`、`log_valid_pixel_count`、`valid_pixel_ratio`、`weight_g`、`sid_num`。
4. `HuberRegressor` 对少量异常样本更稳健，与 `PLSRegression(n_components=10)` 组合后，验证集 RMSE 和 MAE 均有下降。
5. 残差复查显示，当前主要误差仍集中在少数低值被高估、高值被低估的样本上，后续需要进一步补充样本内部信息。

3. 指标对比

阶段	方案	Val R^2	Val RMSE	Val MAE	说明
初始正式模型	单模型基线	0.7227	0.2373	-	正式训练起点
上一阶段最优	`SG1 + GA + PLSR` 双模型融合	0.8221	0.1901	0.1632	上一版阶段汇报采用结果
本轮最优	`SNV + SG1 + PLS10 + batch_quality + Huber`	0.8502	0.1744	0.1449	当前建议采用的正式结果

本轮最佳模型在 Train 和 Val 上的指标如下：

Split	N	R^2	RMSE	MAE
Train	157	0.7530	0.2201	0.1485
Val	40	0.8502	0.1744	0.1449

指标变化如下：

对比口径	指标	对比值	本轮值	绝对变化	百分比变化
相对上一阶段最优	Val R^2	0.8221	0.8502	+0.0281	+3.4%
相对上一阶段最优	Val RMSE	0.1901	0.1744	-0.0157	-8.2%
相对上一阶段最优	Val MAE	0.1632	0.1449	-0.0183	-11.2%
相对初始正式模型	Val R^2	0.7227	0.8502	+0.1275	+17.6%
相对初始正式模型	Val RMSE	0.2373	0.1744	-0.0629	-26.5%

说明：本轮模型使用了批次类别特征。该信息来自样本目录中的批次名称，只使用类别身份，不使用验证集含油率值。由于当前 Train/Val 中存在批次重叠，因此该结果适合代表当前正式划分下的工程效果，不能直接等同于严格跨批次泛化结果。

4. 训练集与验证集数据分析

本节按大类统计，不再把编号后缀当成独立类别。例如 `云南竹叶椒1`、`云南竹叶椒2` 统一计为 `云南竹叶椒`；`刺壳3-1`、`刺壳3-2` 统一计为 `刺壳`。按该口径统计后，当前 processed 数据共 `11` 个大类，Train 和 Val 均覆盖全部 `11` 个大类。

4.1 数据规模与目标值分布

Split	样本数	大类数	每类最少样本	每类最多样本	每类中位数	含油率均值	含油率标准差	含油率范围
Train	157	11	4	27	13.0	1.4717	0.4443	0.3094 ~ 3.1701
Val	40	11	2	8	3.0	1.4183	0.4564	0.3651 ~ 2.4500

从目标值分布看，Train 和 Val 的含油率均值、标准差接近，整体分布没有明显整体偏移。但 Train 中最高含油率达到 `3.1701`，Val 最高为 `2.4500`，高含油率极端样本在验证集中覆盖仍不足。

4.2 各大类样本数量

大类	Train N	Val N	合计 N	Val占比	含油率均值
云南竹叶椒	12	2	14	14.3%	2.3573
云南藤椒	27	8	35	22.9%	1.2186
刺壳	9	2	11	18.2%	1.6030

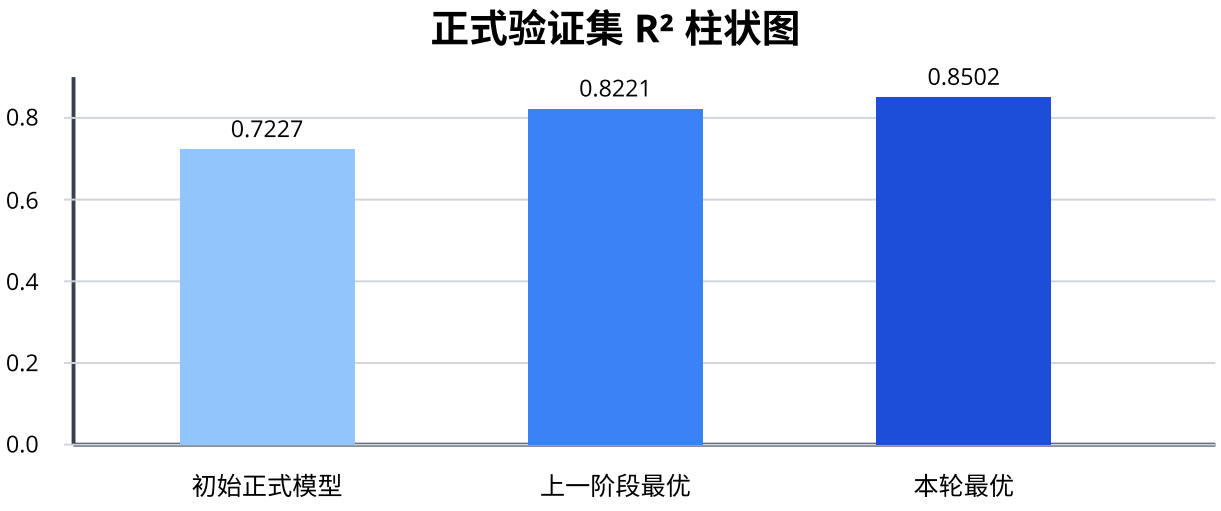
大类	Train N	Val N	合计 N	Val占比	含油率均值
大巴山野生椒	8	3	11	27.3%	1.2833
奉节竹叶椒	18	3	21	14.3%	1.2705
德阳青花椒	13	5	18	27.8%	1.8923
早熟九叶青	20	5	25	20.0%	1.4991
枸椒	21	2	23	8.7%	1.4046
湖北金宏椒	15	4	19	21.1%	1.7311
贵州藤椒	10	4	14	28.6%	1.0152
韩城大红袍	4	2	6	33.3%	0.4588

4.3 类别均衡性判断

1. 按大类合并后，Train 和 Val 都覆盖了全部 `11` 个大类，不存在某个大类只在训练集或只在验证集中出现的问题，验证集覆盖面比按小编号统计时更合理。
2. 类别数量仍不均衡。Train 中最多的是 `云南藤椒`，有 `27` 个样本；最少的是 `韩城大红袍`，只有 `4` 个样本，最大/最小比例约 `6.8:1`。
3. Val 中最多的是 `云南藤椒`，有 `8` 个样本；`云南竹叶椒`、`刺壳`、`枸椒`、`韩城大红袍` 各只有 `2` 个样本，最大/最小比例为 `4:1`。因此当前 Val 可以用于观察总体指标变化，但对少数大类的单类结论仍不够稳定。
4. 从含油率均值看，各大类差异明显，例如 `云南竹叶椒` 均值约 `2.3573`，`韩城大红袍` 均值约 `0.4588`。模型可能会利用大类先验获得较好结果，因此后续需要同时关注大类内样本差异，而不能只看总体 R^2。
5. 当前本轮模型使用了 `batch_quality` 特征，批次/类别信息对正式 split 有帮助，但如果后续要证明跨产地、跨批次泛化能力，还需要单独设计更严格的 batch-holdout 或 category-holdout 验证。

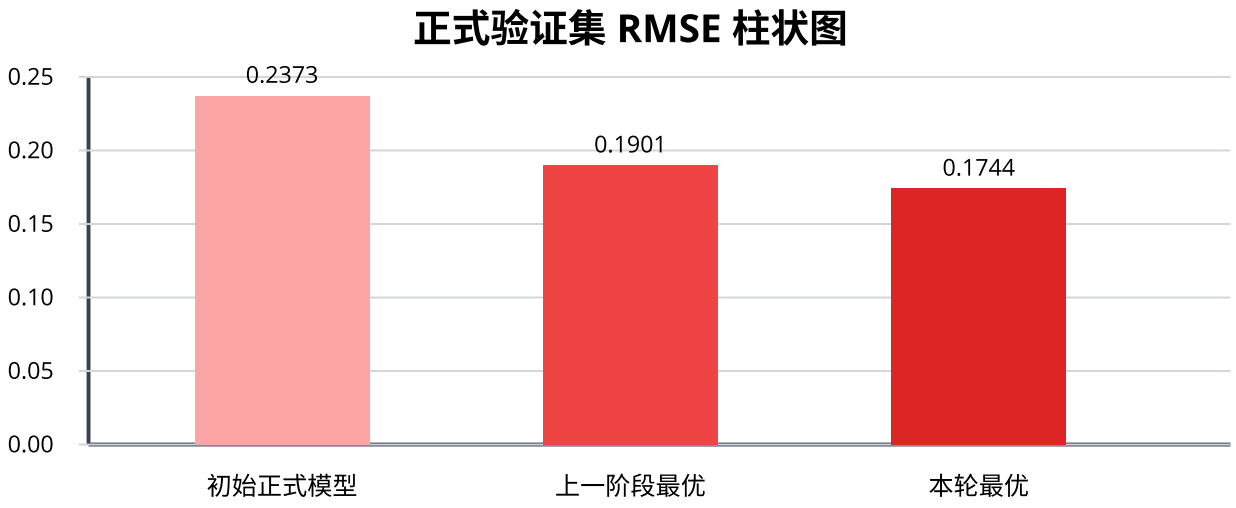
5. 图表

5.1 正式验证集 R^2 提升



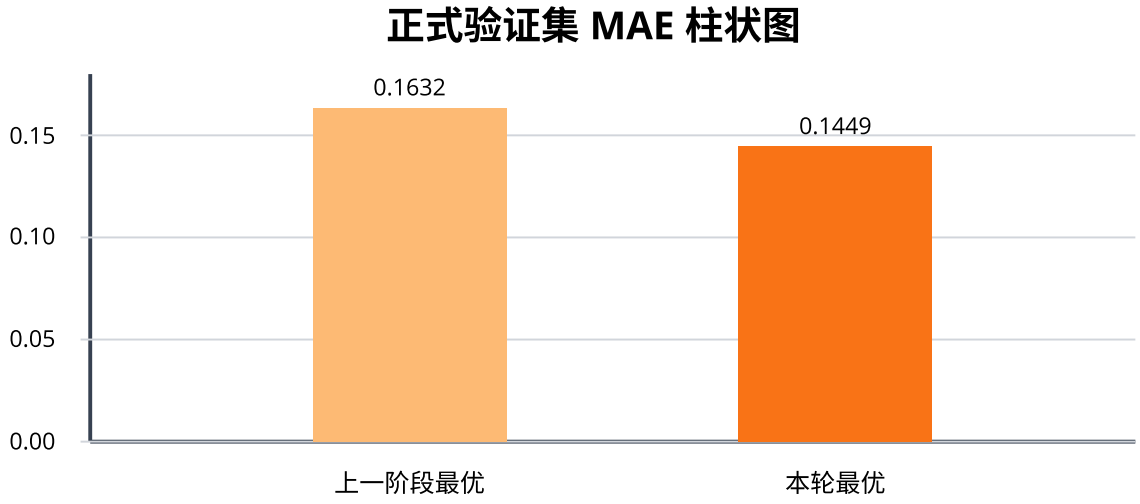
5.2 正式验证集 RMSE 下降

下图纵轴上限设为 `0.25`，柱越低表示误差越小。



5.3 正式验证集 MAE 下降

初始正式模型未记录 MAE，因此下图对比上一阶段最优与本轮最优。



6. 误差观察

本轮最佳模型在 Val 中误差较大的样本如下：

sample_id	batch	actual	predicted	error	abs_error
0193_11	奉节竹叶椒1	0.9292	1.2893	0.3601	0.3601
0351_11	湖北金宏椒3	2.3013	1.9678	-0.3334	0.3334
0196_11	奉节竹叶椒1	0.8787	1.1961	0.3174	0.3174

sample_id	batch	actual	predicted	error	abs_error
0164_11	云南藤椒1-1	0.9422	1.2526	0.3104	0.3104
0169_11	云南竹叶椒2	2.1064	2.4144	0.3080	0.3080

主要现象：

1. `奉节竹叶椒1` 两个低值样本被预测偏高，是当前 MAE/RMSE 的主要来源之一。
2. `湖北金宏椒3` 高值样本仍有低估现象。
3. `云南藤椒1-*` 内部存在样本级差异，单靠批次类别和均值光谱还不能完全区分。
4. 继续提升模型效果时，应重点补充 ROI 内部像素分布、分位数、波段方差和纹理等信息。

7. 下一阶段建议

结合按大类合并后的数据分布，下一阶段不建议只继续做模型超参搜索，应优先补强数据覆盖、类别均衡和样本内部表达。

1. **需要继续增加数据**：当前总样本量为 `197` 个，按大类看只有 `11` 类，单类样本量仍偏小。尤其是 `韩城大红袍` 总样本只有 `6` 个，`刺壳` 和 `大巴山野生椒` 各 `11` 个，明显少于 `云南藤椒`、`早熟九叶青`、`枸椒` 等类别。
2. **优先补充少样本大类**：建议优先补充 `韩城大红袍`、`刺壳`、`大巴山野生椒`、`贵州藤椒`、`云南竹叶椒`。如果条件允许，可先把每个大类的训练样本补到不少于 `15` 个，验证样本补到不少于 `5` 个。
3. **补齐验证集薄弱大类**：当前 Val 中 `云南竹叶椒`、`刺壳`、`枸椒`、`韩城大红袍` 都只有 `2` 个验证样本；`大巴山野生椒`、`奉节竹叶椒` 也只有 `3` 个验证样本。后续新增验证样本时应优先覆盖这些大类，避免少数样本决定单类误差判断。
4. **继续补充高误差相关类别样本**：本轮残差较大的样本主要涉及 `奉节竹叶椒`、`湖北金宏椒`、`云南藤椒`、`云南竹叶椒` 等大类。建议在这些大类内部补充不同含油率区间的样本，尤其是低含油率和高含油率端点样本。

8. 总结

1. **效果继续提升**：本轮正式验证集 R^2 达到 `0.8502`，较上一阶段最优提升 `+0.0281`，相对提升约 `3.4%`。
2. **误差明显下降**：`Val RMSE` 较上一阶段下降约 `8.2%`，`Val MAE` 下降约 `11.2%`。
3. **当前正式推荐方案**：`SNV + SG一阶导 + PLS10 + batch_quality + Huber`。
4. **后续重点**：下一阶段应优先补充少样本大类和高误差大类样本，同时增加 ROI/像素级统计特征，并新增更严格的跨批次验证口径。