

基于高光谱成像的 3D-WPCA-CNN 模型评估花生仁含油率

宋安然^{1,2,3}，郭新宇^{1,3*}，顾生浩^{1,3}，陈晓茜^{1,3}，王柏雁^{1,3}

(1. 北京市农林科学院信息技术研究中心，北京 100097；2. 北京科技大学化学与生物工程学院，北京 100083；

3. 国家农业信息化工程技术研究中心，北京 100097)

摘要：花生种子含油率的快速、无损和精准预测对于加速育种过程以及满足食品工业需求具有重要意义。该研究提出了一种结合自定义加权平均池化和通道注意力机制的三维卷积神经网络(3D weighted pooling and channel attention convolutional neural network, 3D-WPCA-CNN)模型。为了提高单粒花生种子含油率的预测精度，提出了一种加权平均池化层，该层通过引入可学习的权重参数优化池化过程。集成了通道注意力机制，能够自适应地调整每个通道的特征响应，进一步提升了对高光谱图像中重要信息的提取能力。为了验证模型的优越性，将所提方法与基于平均光谱的卷积神经网络(convolutional neural network, CNN)模型进行比较。结果表明：所提 3D-WPCA-CNN 模型在预测含油率方面表现优异，具有较高的决定系数($R^2=0.809\ 2$)和较低的均方根误差(RMSE=1.713 1%)，显著优于基于平均光谱模型($R^2=0.698\ 3$, RMSE=2.183 7%)、无注意力机制的平均池化 3D-CNN 模型($R^2=0.721\ 7$, RMSE=2.069 3%)以及未添加通道注意力机制的加权平均池化 3D-CNN 模型($R^2=0.738\ 4$, RMSE=2.005 9%)。此外，该 3D-WPCA-CNN 模型的相对预测偏差(RPD=2.338 9)较好，进一步证实了其可准确预测花生含油率。该研究可为基于高光谱图像的作物籽粒组分预测提供高维度建模思路，对精确预测花生等农作物的品质特性具有重要的实践价值。

关键词：花生仁；高光谱图像；含油率；通道注意力机制；3D 卷积神经网络

doi: 10.11975/j.issn.1002-6819.202502028

中图分类号: S-3

文献标志码: A

文章编号: 1002-6819(2025)-10-0322-10

宋安然, 郭新宇, 顾生浩, 等. 基于高光谱成像的 3D-WPCA-CNN 模型评估花生仁含油率[J]. 农业工程学报, 2025, 41(10): 322-331. doi: 10.11975/j.issn.1002-6819.202502028 <http://www.tcsae.org>

SONG Anran, GUO Xinyu, GU Shenghao, et al. Evaluation of peanut kernel oil content using 3D-WPCA-CNN based on hyperspectral imaging[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2025, 41(10): 322-331. (in Chinese with English abstract) doi: 10.11975/j.issn.1002-6819.202502028 <http://www.tcsae.org>

0 引言

花生是在热带、亚热带和暖温带广泛种植的油料作物，是全球食品、食用油和饲料的重要来源^[1-2]。其种子风味独特，营养价值高^[3]，因而在食品工业和健康膳食中具有重要地位。尤其是花生油，富含不饱和脂肪酸。因此，花生的营养品质，尤其是油脂含量，成为育种改良的重要目标之一^[4]。在花生品质评价体系中，油脂含量不仅直接影响食用品质和加工特性，也是决定榨油效率与经济价值的关键指标。因此建立一种快速、准确且高效的油脂含量检测方法，对于加速花生育种、提升品种选优效率以及满足食品工业和消费市场对高品质油料产品的需求，具有重要的现实意义和应用价值。

在油脂含量测定领域，索氏提取法、核磁共振和近红外光谱^[5]均为当前常用的方法。其中索氏提取法是一种经典的油脂提取方法，但是这种方法效率低、操作复杂、试剂易造成环境污染且需要对种子破坏性取样。研究

表明，即使在同一品种或批次中，花生种子的营养成分也可能存在变异。这种变异性对精准育种、优质种子筛选及遗传资源评价具有重要影响^[6]。与之相比，核磁共振不需要试剂参与，但效率仍然有限，不能满足大批量单粒种子高通量检测的需求。近红外光谱技术可以迅速处理大量样本，但利用单点或有限取样点的光谱信息代表整个样品可能存在偏差。高光谱成像技术结合光谱和成像，可以获取完整样本的光谱信息，克服了光谱技术的局限性。高光谱图像由于其高通量特性和丰富的信息，在作物表型研究、食品检测等领域发挥了重要作用^[7-10]。

随着对作物品质精准评价的需求不断增长，利用高光谱成像技术进行无损、快速的单粒种子品质分析成为研究热点。大量研究表明，基于近红外高光谱成像结合化学计量法或机器学习，可在单粒尺度上实现种子的生化组分定量预测^[11-14]、成熟度^[15]以及活力^[16-18]等品质的定性评估。在种子的营养组分评估中，高光谱成像技术可以获取种子的全局信息，尤其适用于单粒种子蛋白质、淀粉、脂肪和水分等成分检测。鉴于光谱信息与生化组分的密切相关性，研究通常选用图像中感兴趣区域的平均光谱信息作为建模特征，构建机器学习模型进行成分含量的回归预测。传统机器学习，如偏最小二乘回归(partial least squares regression, PLSR)，因数据量和计算资源要求低、模型透明度高以及训练速度快在高光谱数据处理中得到广泛应用^[4,12,19]。这些方法虽然在一些

收稿日期: 2025-02-02 修订日期: 2025-04-18

基金项目: 山东重点研发计划项目(2021 LZGC026); 北京市农林科学院作物表型组学协同创新中心项目(KJCX20240406)

作者简介: 宋安然, 博士生, 研究方向为现代化学分析。

Email: 18854803908@126.com

*通信作者: 郭新宇, 博士, 研究员, 研究方向为作物表型组学。

Email: guoxy73@163.com

任务中取得了一定效果，但其建模过程依赖于特征选择和降维方法的人工配置，缺乏系统的选择标准，通常需要大量的经验、专业知识和人工组合^[20-22]。为提升性能，研究者尝试引入多种机器学习算法集成和多阶段参数优化技术，以探寻最佳算法和参数组合^[20]。但传统的机器学习方法处理高光谱步骤繁杂，依赖特征工程。此外，随着数据量的增加，传统机器学习在可扩展性方面也面临瓶颈。近年来，CNN 和深度学习在高光谱图像解析中的应用日益增多^[23-24]，尤其是在种子分类分级^[15,25-26]、感染检测^[27,28]、活力评估^[17,29]等任务中表现出色。在成分预测回归任务中，也有部分研究将 CNN 架构引入回归建模^[30]。目前，油料作物如大豆、花生和油菜的单粒含油量检测研究逐渐受到关注。与其他种子研究的进展类似，部分学者已经将高光谱成像技术应用于该领域^[11,31-33]。

然而，当前主流的机器学习和 CNN 模型多基于平均光谱信息建模，忽略了图像的空间维度和结构特征，从而限制了模型对种子间个体差异的感知能力。例如，花生种子大小和含油量差异存在一定相关性^[34-35]，但目前的研究往往未将这些空间信息纳入建模范畴。因此，基于高光谱原始图像构建 3D-CNN 模型，是捕获更丰富特征以提高组分预测精度的有效方法。

高光谱图像通常具有数十到数百个光谱波段，数据维度高且包含空间信息。3D-CNN 能够同时处理空间（2D）和光谱（1D）3 个维度的数据，使得模型能够在空间和光谱维度捕获更多的特征，从而提高分类^[36]、变化检测^[37]等任务的性能。在组分预测等回归任务中，3D-CNN 也能够捕捉到高光谱图像中更多的关联特征。综上，基于高光谱图像构建 3D-CNN 模型具有显著优势^[38]。

为了增加高光谱图像的特征捕获能力和组分预测精度，本研究提出了基于加权池化和通道注意力机制的 3D-CNN。并在 98 个花生品种中验证该方法的有效性和适用性。以期为解决传统 1D-CNN 方法在高光谱图像分析中存在的空间信息丢失问题提供解决思路和技术路径。

1 材料与方法

1.1 花生样本及高光谱图像获取与矫正

花生于山东省泰安市宁阳县山东农业科学院实验基地（35°50'57"N，116°39'50"E）种植，土壤类型为壤土。成熟后收获，放置于牛皮纸袋中，含水率约 8%，于阴凉通风处保存。所有种子由山东省农科院提供。为了构建可靠的油脂预测模型，筛选了山东及其周边各省的 100 个花生品种，其含油率覆盖范围约为 40% ~ 65%。在每个品种中，随机选择 18 粒健康种子作为试验样本。

高光谱成像系统的光谱范围为 930 ~ 2 548 nm，数据获取的设备如图 1a 所示。花生种子样本放置于 3D 打印的尼龙板上（图 1b），使用相互作用模式获取 6 行 6 列种子的高光谱图像。该系统放置于暗箱中，由高光谱相机（光谱仪 ImSpector N25E，Spectral Imaging Ltd, Oulu, Finland 和像素阵列 Xeva-2.5-320，Xenics Ltd, Belgium）、2 个卤素线光源、电机驱动的电动定位样品台和计算机组成，配备 SpectraCube 数据采集软件和样品台控制软件（台湾五十铃光学公司）。数据采集时，样

品-光源与样品-相机的夹角约为 30°，样品到光源的垂直距离为 30 cm。电机以 43 mm/s 移动样品台，相机光谱仪单元以 4 ms 曝光时间逐行扫描花生样品。

每个花生种子的高光谱图像包含 256 张单波长图像，波长分辨率约为 6.32 nm。原始高光谱图像经过经典的白板矫正公式，得到转化后的图像。当灯关闭并且镜头盖上黑色盖子时，收集暗参考图像，白色参考图像是从具有 99% 反射率的白色漫反射板（Spectralon SRT-99-100，Labsphere Inc., North Sutton, NH, USA）上获得。矫正公式 (1) 如下：

$$IR = \frac{I_r - I_d}{I_w - I_d} \times 100\% \quad (1)$$

其中 IR 是校正后的图像相对反射率； I_r 是原始高光谱图像反射光强度； I_w 和 I_d 分别代表白色参考图像和黑暗参考图像反射光强度。

试验中，每张高光谱图像包含 36 个花生种子，布局为 6 行 6 列。该部分通过排序定位和二值化掩模技术实现种子的高通量分割（图 1c），选择的掩模波段是第 30 个波段（该波段较稳定且光强与背景相差大）。分割后，单粒种子的感兴趣区域从原始尺寸 $x \times y \times 256$ 扩充为统一尺寸 $100 \times 60 \times 256$ 。在数据采集过程中，因操作错误导致 2 个品种混合，最终得到 98 个品种的有效数据。此外，由于少数种子在获取数据时俯视图存在粘连，试验舍弃这些难以分离单粒种子样本（如图 1d）。最终，试验收集到 98 个品种共 1 737 个有效样本。




图 1 高光谱图像获取与高通量分割

Fig.1 Hyperspectral image acquisition and high-throughput segmentation.

1.2 含油率参考值

花生种子高光谱图像采集完成后，使用 VTMR20-010 V-I 核磁共振成像分析仪（上海纽曼电子科技有限公司，中国）获取单粒花生种子的含油率^[39-40]。为建立数据采集的标准曲线（ $R^2=0.999$ ），市售食用花生油被选为标准物质。样本在数据采集房间中静置 12 h 以上以确保温度稳定，随后进行含油率的测量，获取所有有效样本的相关数据。

1.3 基于平均光谱的 CNN 模型

为了解决传统池化法在高维数据处理中的不足，本文提出了加权平均池化层（weighted average pooling），

其主要目标是通过引入可学习的权重来提升特征提取的灵活性。传统池化方法仅依赖于局部区域的平均值或最大值,与常规的平均池化操作不同,加权池化则根据每个通道的特征重要性分配不同的权重,从而使得每个通道的池化结果可以根据其相对重要性进行调整。具体地,假设输入特征图的形状为 $X \in \mathbb{R}^{C \times L}$,其中, C 是通道数, L 为序列长度。加权池化操作通过对输入特征图进行一维平均池化来减小序列长度,其池化大小由`kernel_size`控制,步幅由`stride`控制。在此基础上,为每个通道引入了可学习的权重 $M_c \in \mathbb{R}^C$,这些权重在训练过程中进行优化。池化操作的输出为 $Y \in \mathbb{R}^{C \times L'}$,其中 L' 为池化后的序列长度。加权池化的过程可以通过式(2)表示:

$$Output_c = (avg_{pool_c}(X)) \cdot M_c \quad (2)$$

其中 $avg_{pool_c}(X)$ 表示对输入特征图进行平均池化操作, M_c 是第 c 个通道的学习到的权重, $Output_c$ 为加权池化后的输出结果。

为了进一步提升特征图中每个通道的表示能力,本文引入了全局注意力机制(global attention)。在传统的CNN中,所有通道对输出的贡献通常是平等的。然而,某些通道对于特定任务可能更为重要,因此设计了一个通道级的注意力机制,自动调整每个通道的权重,从而突出重要特征。假设输入特征图的形状为 $X \in \mathbb{R}^{C \times L'}$,其中 C 是通道数, L' 是经过加权池化处理后的序列长度($\mathbb{R}$ 表示实数域)。全局注意力机制的核心思想是通过学习每个通道的权重系数 $\alpha_c \in \mathbb{R}$,使得网络能够关注更重要的通道特征。在前向传播中,对每个通道的输出应用了一个经过Softmax归一化的注意力权重 α_c ,得到加权后的输出:

$$Output_c = X_c \cdot \alpha_c \quad (3)$$

其中 X_c 表示输入特征图的第 c 通道, α_c 是对该通道的注意力权重。通过这种方式,模型能够在训练过程中自动学

习如何强化对关键特征的关注。


1.4 下采样与数据增强

在基于3D高光图像的任务中,一个关键挑战是如何在有效抑制噪声的同时,尽可能保留光谱细节信息。为了优化高光图像输入质量,采取了下采样策略,以实现噪声抑制与光谱信息保留之间的平衡。在实际操作中,将 $100 \times 60 \times 256$ 的图像在空间维度上采样。具体方法是将空间维度重新排列并对每个小块进行均值聚合,最终得到 $10 \times 6 \times 256$ 的3D高光图像。

虽然降低了高光图像的数据量,但3D-CNN的参数数量仍较大,需要足够的数据驱动。直接利用原始的数据训练模型会导致欠拟合,无法从有限的数据中学习有效的特征。为了提高花生种子高光图像含油率预测模型的能力,使用数据增强策略如下:旋转、镜像反转和噪声添加。为了保留高光图像中感兴趣区域的信息,考虑了微小的角度变化(在不同的角度范围,如 $0^\circ \sim 30^\circ$, $150^\circ \sim 180^\circ$, $180^\circ \sim 210^\circ$,和 $330^\circ \sim 360^\circ$ 四个范围中随机生成2~3次旋转)和 180° 旋转。这使模型更好适应各种倾斜角度的实际情况。然后对图像数据进行了左右和上下的镜像反转。这2种简单的变化能够增加数据的多样性,帮助模型学习不同角度种子的学习能力。另外,在图像中引入高斯噪声,模拟显示世界中的传感器噪声,从而使模型更加适应真实世界的应用场景。通过这种综合的数据增强策略,将训练集从1349扩增到64700张花生种子高光图像。

1.5 3D-WPCA-CNN 模型构建

本文提出了一种基于加权平均池化和通道注意力机制的三维卷积神经网络(3D weighted pooling and channel attention convolutional neural network, 3D-WPCA-CNN)模型,以改进高维数据的特征提取和信息加权。模型包含两个关键模块:加权平均池化层和通道注意力机制。模型结构图如图2所示。



注: B 、 D 、 H 、 W 分别为批处理数、高度、宽度和深度, CA 为通道注意力机制, ReLU 为模型所使用的激活函数, BN 为归一化层。

Note: B , D , H , and W represent batch size, height, width, and depth, respectively. CA denotes the channel attention mechanism, ReLU is the activation function employed in the model, and BN is batch normalization.

图2 基于加权平均池化和通道注意力机制的三维卷积神经网络结构图

Fig.2 3D convolutional neural network architecture diagram with weighted average pooling and channel attention mechanism

该加权平均池化层是通过对输入特征图进行加权平均处理,旨在提升对关键信息的提取和减少无关信息的干扰。与传统的池化方法(如最大池化或均值池化)不同,本层引入了可学习的权重,使得每个通道的特征根据其重要性进行加权平均。加权平均池化操作通过对输

入特征图应用加权3D卷积来实现。卷积核的大小由`kernel_size`参数控制,步幅由`stride`参数决定。卷积核为每个通道分配一个独立的权重矩阵,从而保持各通道之间的独立性。采用分组卷积方式,每个输入通道都有独立的卷积核,从而确保每个通道的特征可以根据不同的

权重进行加权池化。加权池化层中的权重矩阵通过网络训练过程自我调整。初始时，这些权重从标准正态分布中随机初始化。在训练过程中，权重通过反向传播算法不断优化，以使网络能够自适应地识别和增强关键特征。

若输入特征图为 $X \in \mathbb{R}^{C \times H \times W \times D}$ ，其中 C 表示通道数， H 、 W 、 D 分别表示高度、宽度和深度，权重矩阵为 $M \in \mathbb{R}^{C \times H \times W \times D}$ 。加权池化操作可以通过下式计算：

$$T_c = \sum_{h,w,d} X_{c,h,w,d} \cdot M_{c,h,w,d} \quad (4)$$

其中 T_c 表示第 c 通道的加权池化输出， $X_{c,h,w,d}$ 和 $M_{c,h,w,d}$ 分别为输入特征图和权重矩阵的元素， Σ 表示做加权求和。

在传统 CNN 中，每个通道对输出的贡献是等价的，但在实际应用中，某些通道可能对特定任务更为重要。为了解决这一问题，引入了通道注意力机制，旨在自动地为每个通道分配一个重要性权重，从而突出重要通道并抑制无关通道。

通道注意力机制的核心是通过输入特征图的通道维度进行加权来提高重要通道的贡献。具体而言，首先通过一个全局平均池化层计算每个通道的全局描述，然后通过一系列全连接层学习每个通道的权重。给定输入特征图 $X \in \mathbb{R}^{C \times H \times W \times D}$ ，首先对每个通道进行全局平均池化，得到一个通道描述向量 $Z_c \in \mathbb{R}^C$ 。然后通过一个小型的全连接网络（即一个具有 ReLU 激活函数的隐藏层和一个 sigmoid 激活的输出层）对该描述向量进行处理，生成每个通道的注意力权重 α_c ：

$$\alpha_c = \sigma(M_2 \cdot \text{ReLU}(M_1 \cdot Z_c + b_1) + b_2) \quad (5)$$

其中 M_1 、 M_2 是全连接层的权重矩阵， b_1 、 b_2 是偏置值， σ 是 sigmoid 激活函数。最终，输入特征图 X 将通过通道注意力权重进行加权处理。对于每个通道 c ，其输出为：

$$X'_c = \alpha_c \cdot X_c \quad (6)$$

其中 X'_c 是加权后的输出特征。

该模型通过结合加权平均池化和通道注意力机制，不仅能够空间维度上进行有效的信息汇聚，还能在通道维度上通过学习得到重要特征的加权表示。这种多层次的特征加权策略增强了网络的表现能力，特别是在高维数据（如 3D 图像、视频或医学图像等）处理任务中，能够更好地捕捉复杂的空间和通道特征，从而提升模型的性能。

1.6 模型评估

本文中的回归模型采用决定系数（coefficient of determination, R^2 ）、均方根误差（root mean square error, RMSE）、相对预测偏差（relative performance deviation, RPD）^[12,41] 评估。决定系数衡量模型准确性，均方根误差反映相应集合中预测值和实际值之间的平均差异。RPD 可进一步度量模型的定量预测能力和稳定性。上述参数计算公式如下：

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - Y_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (7)$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - Y_i)^2} \quad (8)$$

$$\text{RPD} = \frac{\text{SD}}{\text{RMSE}} \quad (9)$$

其中 y_i 和 Y_i 表示第 i 个单粒花生种子的含油率实测值和预测值， $\bar{y}$ 是所有花生种子油脂含量实测值的平均值， n 是校准或预测集中的样本数。SD 为参考值的标准差。RPD 值越大，说明模型的预测性能越好；反之，则模型的定量能力相对较弱。具体地，当 $\text{RPD} \geq 2.5$ 时，模型具有极强地预测能力；当 $2.0 \leq \text{RPD} < 2.5$ 时，认为模型预测能力较强，可用于决策支持；当 $1.4 \leq \text{RPD} < 2.0$ 时，表明模型预测能力一般；如果 RPD 小于 1.4，表明模型预测能力预测较差^[42-43]。

所有数据处理和模型构建使用 Python 3.8 编程语言，模型训练在具备 Intel® Xeon® Silver 4314（2.40 GHz，32 cores）CPU、NVIDIA GeForce RTX 4070 GPU 的环境中完成。

2 结果与分析

2.1 花生含油率与光谱-空间特征分析

图 3a、3b 显示了 98 个花生品种的种子质量、粗脂肪质量和含油率的分布曲线和轴须图。3 个分布曲线的峰值接近 0 且接近对称的形状，表明数据分布类似正态分布，没有显著的尖峰或平坦特性。所有特征的偏度接近 0，没有显著偏斜。含油率的中心位于 53.78% 左右，这表明大部分数据围绕这一中心聚集。下部轴须清晰地标示了数据的实际范围，含油率从最低的 39.99% 到最高的 65.97%。这一数值跨度表明虽然大部分品种的含油率较为集中，但仍有一些极端值存在。同时，轴须尾部标出了几个离群点，可能指向特定品种异常高的含油率或不成熟种子的低含油率。总之，数据在 3 个层面展现了一定的正态分布特征，且含油率分布广泛，说明数据的代表性，是利用 CNN 进行建模的良好基础。

光谱特征反映了光与物质的相互作用，包括化学和物理属性。图 3c 展示了“开 192”花生种子的感兴趣区域的平均光谱以及感兴趣区域内 100 个随机像素的光谱曲线。花生种子感兴趣区域的平均光谱特征反映了总体趋势和主要吸收峰。其中，每个像素点都具有独立的光谱特性，能够揭示局部变化。原始像素点的光谱信息具有较大差异，其中整体强度差异可能由于种子三维形状，而局部的峰强度差异可能来自组分差异。感兴趣区域的平均光谱为分析提供了一定的便利，但可能导致信息损失。尤其是在光谱数据中独特的特征峰和特征谷被平均化而模糊，以及三维空间的影响。然而，每个像素的光谱特征具有较多噪声，尤其是在第 150 ~ 250 个波段的区间内。

为了充分利用原始高光谱图像中的信息并保持数据的完整性，本研究采用了空间系采样技术来处理高光谱数据。图 3d 为“开 192”花生种子空间下采样后的感兴趣区域的平均光谱和 20 个随机像素点的光谱曲线。这种方法可以有效减少数据的总体量，同时降低噪声水平。具体地，将相邻像素逐通道的光谱值进行合并，计算平均值。这样不仅保留了各个像素点中的详细光谱信息，

而且也使得数据更加稳定和可靠。





图3 花生的含油率与光谱特征

Fig.3 Oil content and spectral characteristics of peanuts



注：图中展示的是测试集的 RMSE 和 R^2 。

Note: The figure presents the RMSE and R^2 values for the test set.

图4 训练过程的训练集和测试集的损失变化及结果

Fig.4 Changes in training and testing loss during the training process and results

从训练过程看，周期为 300，批处理大小为 16，学习率为 0.000 3 是最佳的超参数设置，它能够使得训练和

2.2 基于平均光谱的花生含油率预测结果

本节比较了不同学习率、批处理大小和训练周期等超参数对模型性能的影响。不同超参数组合下，训练过程的训练集、测试集的损失如图 4 所示。

随着训练的进行，所有超参数组合的损失持续下降。但在 100 周期后，损失变化趋于平缓。这可能是因为初始损失较大，使图中下降幅度较小。然而，尽管变化较小，模型的性能仍在逐步提升，并未出现明显的过拟合和欠拟合现象。在不同的训练设置中，训练周期为 300，批处理大小为 16，学习率为 0.000 3 时表现出最好的性能平衡，既能保证训练损失的下降，又在测试集上表现出较好的泛化能力（图 4e）。相比之下，较低的学习率（0.000 1）导致了较慢的收敛速度，表现较差，模型难以有效拟合数据（图 4b）。而较高的学习率（0.001）则可能导致训练过程中的不稳定，导致训练和测试损失下降幅度较小（图 4c）。批处理大小对模型的表现有显著影响，批处理大小为 16 通常提供了更好的泛化能力，而较大的批处理大小可能导致模型的表现略逊一筹（图 4h）。

为了进一步验证训练周期的选择，对比了 200~400 训练周期的模型性能。结果表明 300 训练周期的模型表现优于 200 训练周期，而继续增加至 400 训练周期后，模型精度未出现明显提升。因此，认为 300 训练周期是当前任务下较优的选择，可在模型性能与计算成本之间取得良好平衡（图 4d、4e、4f）。

测试损失都较为平衡，并且测试集的损失下降幅度较大，表明模型具有较好的泛化能力。其他设置，如较大的学

习率或较小的批处理大小，导致了训练过程中较大的波动或较差的泛化能力。因此，在实际应用中，建议选择合适的学习率和批处理大小来确保模型的稳定收敛，并通过适当增加训练轮次来进一步提升性能。

图 5 展示了不同超参数下训练集和测试集的 R^2 和 RMSE。图 5a、5d 对比了不同学习率（0.001、0.000 3、0.000 1）下的模型性能。学习率为 0.000 1 时使得模型的表现较差，训练数据和测试数据的 R^2 评分较低，RMSE 较高，这表明模型可能未能充分学习到数据的特征，可能导致收敛速度过慢或陷入局部最优解。较高的学习率（如 0.001）虽然训练较为迅速，但模型在测试集上的泛化性能较差，表现不如中等学习率（0.000 3）时的效果。总体来看，0.000 3 的学习率提供了一个较好的平衡，能使得模型较好地学习数据，同时具有较好的泛化能力。

训练周期从 200~300，随着训练周期增加，模型精度提升。训练周期从 300~400 的变化看，较长的训练周期（如 400 轮）并未提升模型性能，甚至在一些情况下，可能导致过拟合的风险增加（如在不同学习率和批处理大小设置下，训练集性能虽有提升，但测试集 R^2 评分变化不大）（如图 5b、5e）。这表明，虽然增加训练周期能进一步提高训练数据上的准确度，但对于测试数据的泛化性能提升有限，可能已经达到了性能瓶颈。

如图 5c、5f 所示，当批处理大小为 16 时，模型在训练数据和测试数据上的表现较佳（如训练周期为 300，

批大小为 16，学习率为 0.000 3 时 R^2 为 0.707 9）。这一结果表明较小的批处理大小可以加速收敛，同时提供更高的精度。相比之下，批处理大小为 32 时，虽然训练数据表现不错（ R^2 为 0.529 3），但测试数据的性能却有所下降（ R^2 为 0.489 3）。而较小的批处理（如 8）也表现出了相对较好的效果，但稍逊色于 16。可以推测批处理大小为 16 时，训练过程中的梯度更新较为稳定，且模型有足够的容量进行有效学习。

在某些超参数配置下，训练数据的 R^2 明显高于测试数据，这表明可能存在过拟合。例如，当学习率为 0.000 1 时，模型在训练数据上的 R^2 为 0.407 4，测试数据的 R^2 为 0.350 9，性能较差。可能是因为学习率过低导致模型没有学到足够的特征，甚至在训练数据上也未能充分拟合。相反，在训练周期为 300，批大小为 16，学习率为 0.000 3 的情况下，训练数据和测试数据的 R^2 评分和 RMSE 值都达到了较好的平衡，未出现明显的过拟合或欠拟合。

从所有试验结果来看，最优的超参数设置是训练周期为 300，批大小为 16，学习率为 0.000 3，这一设置下模型在测试集上表现最好， R^2 值为 0.694 5，RMSE 值为 2.197 4%，表明模型既能够较好地拟合训练数据，又具备较强的泛化能力。通过对比不同超参数组合下的表现，可以得出结论：学习率为 0.000 3，批处理大小为 16，训练周期为 300 次的配置是较优的，这为后续模型改进和优化提供了有价值的参考。




图 5 不同超参数下训练集和测试集的 R^2 和 RMSE 对比

Fig.5 Comparison of R^2 and RMSE for training and test sets under different hyperparameters

2.3 基于 3D-WPCA-CNN 的花生含油率评估结果

为了比较基于平均光谱模型和基于空间-光谱模型的

表现，本节利用与平均光谱模型相同的超参数优化方法（网格搜索）找到 3D-WPCA-CNN 模型的最佳性能的超

参数组合（学习率为0.000 3，批处理大小为 32，周期为 300）。在该组合下，模型训练过程的训练集和测试集的损失和 R^2 变化如图 6 所示。随着训练周期的增长，训练集和测试集的损失均逐步降低。




图 6 训练过程中训练集和测试集表现

Fig.6 Performance of training and test sets during the training process

在训练初期，训练损失从 239.557 8 下降至 10.144 9，表现出模型正在逐步适应训练数据（前 10 个周期）。在第 1 个周期时，测试损失为 16.759 4，相比训练集的损失明显更低。随着训练的进展，测试损失缓慢下降，最终在第 16 个周期降至 6.894 7。数据增强增加了训练集的多样性，因此模型在初期需要更多的时间来适应这些变换。此时，训练损失较高，而测试损失较低，表明模型在增强数据上尚未找到合适的映射关系，而在原始测试数据上表现相对更好。

训练 R^2 从第 1 个周期的-14.033 6 上升到第 16 个周期的 0.530 0，显示出模型在训练集上的拟合性能逐渐提升。前期 R^2 值的上升幅度较大，表明模型在增强数据的情况下开始逐渐学会如何有效提取特征，提升对训练数据的预测能力。同样地，测试集的 R^2 从第 1 个周期的-0.089 4 上升至第 16 个周期的 0.551 8。初期测试集的表现明显优于训练集，说明测试数据没有被增强，因此模型在这部分数据上能够表现得更好。随着训练进行，模型逐渐适应了增强数据，测试集的表现也逐步提升。

随着训练的深入，训练集和测试集的损失和 R^2 开始趋于一致。特别是在第 10 个周期之后，训练损失和测试损失开始接近，显示出更相似的表现。这是一个积极的信号，表明模型的训练不仅能够更好地拟合训练数据，还能够有效地泛化到未经增强的测试数据。这种趋同的现象表明，随着训练的推进，模型已逐渐掌握了增强数据中的模式，并且对训练和测试数据的拟合能力都得到了提升。最终，训练集和测试集的 R^2 值（0.822 8 和 0.809 2）接近，表明模型在增强数据上的泛化能力得到了有效提升。

从表 1 可以看出，在训练集和测试集上，3D-CNN 模型均优于 1D-CNN，表现出更好的拟合能力和更强的泛化能力。具体来说，3D-CNN 的 R^2 值明显高于 1D-CNN，且 RMSE 值较低，表明其预测误差更小。在训练集上，3D-CNN 的 R^2 为 0.822 8（300 周期），显著高于 1D-CNN 的 0.707 9 和 0.713 5。此外，3D-CNN 在训练集和测试集的 RMSE 分别为 1.680 4% 和 1.713 1%，低于

1D-CNN 的 2.124 9% 和 2.183 7%，显示其更好的拟合效果和更高的预测准确性。在测试集上，3D-CNN 同样表现优于 1D-CNN。300 周期时，3D-CNN 的 R^2 为 0.809 2，1D-CNN 为 0.694 5；400 周期时，1D-CNN 为 0.698 3。

表 1 1D-CNN 和 3D-CNN 模型的表现对比

Table 1 Comparison of the performance of 1D CNN and 3D CNN models

模型 Model	周期 Epoch	训练集 Train set		测试集 Test set		
		R^2	RMSE/ %	R^2	RMSE/ %	RPD
基于注意力机制的卷积神经网络 ACNNR	1 000	-0.025 2	4.169 2	0.089 4	4.087 8	0.972 5
一维卷积神经网络 1D-CNN	300	0.707 9	2.145 6	0.694 5	2.197 4	1.809 1
一维卷积神经网络 1D-CNN	400	0.713 5	2.124 9	0.698 3	2.183 7	1.820 5
无注意力机制的平均池化三维卷积神经网络 3D average pooling convolutional neural network without channel attention	300	0.694 1	2.207 8	0.721 7	2.069 3	1.936 3
无通道注意力机制的加权平均池化三维卷积神经网络 3D weighted pooling convolutional neural network without channel attention	300	0.799 5	1.787 4	0.738 4	2.005 9	1.997 5
加权平均池化和通道注意力机制的三维卷积神经网络 3D-WPCA-CNN	300	0.822 8	1.680 4	0.809 2	1.713 1	2.338 9

注：批处理大小为 16，学习率为 0.000 3。

Note: The batch size is 16 and learning rate is 0.0003.

在此基础上，为更全面地评价模型的定量预测能力，计算了 RPD 指标，其中 3D-CNN 模型的 RPD 为 2.338 9。根据常见的经验划分， $2.0 \leq \text{RPD} < 2.5$ 通常表示模型具有一定的定量能力，能够较为准确地进行预测。

ACNNR 模型进行了 1 000 次迭代，并尝试了 4 种学习率（0.03，0.01，0.03，0.001）和批处理大小（16，32，64，128），最佳超参数组合是学习率为 0.001 和批处理大小为 16，得到的效果不理想（如表 1 所示）。在测试集上，3D-WPCA-CNN 的表现（ $R^2=0.809 2$ ，RPD=2.338 9）优于基于平均光谱的模型（ $R^2=0.698 3$ ，RPD=1.820 5； $R^2=0.089 4$ ，RPD=0.972 5）和无注意力机制的平均池化三维卷积神经网络（ $R^2=0.721 7$ ，RPD=1.936 3）以及未添加通道注意力机制的模型（ $R^2=0.738 4$ ，RPD=1.997 5）。3D-CNN 在测试集上的 R^2 值较高，说明其具有更强的泛化能力，能够在未见数据上保持较低的预测误差。总的来说，3D-CNN 模型在训练过程中能够更好地拟合数据，并且在测试集上表现出更好的泛化能力，相比 1D-CNN，具有更低的预测误差和更高的准确性。

3 讨论

3.1 基于光谱特征的模型

传统的基于光谱特征的模型通常依赖单一的光谱数据或平均光谱特征进行建模。这类方法能够揭示种子成分与光谱特征之间的基本线性或非线性关系，但往往忽视了种子内部成分的空间分布特征^[42,44]。近年来，随着高光谱成像技术的发展，光谱特征的细粒度信息逐渐得到广泛应用。然而，单纯依赖光谱数据仍存在一定的局

限性，尤其是在需要高精度表征种子内在复杂结构时。本研究提出的 3D-WPCA-CNN 的模型，充分利用了光谱图像的高维特性，通过深度学习模型的自动特征提取能力，能够更精确地捕捉花生种子含油率与其光谱特征之间的复杂关系。通过自定义加权平均池化层，模型能够动态调整各个光谱通道的权重，从而更有效地突出与目标成分相关的关键信息，提高了预测模型的精度。

3.2 基于空间-光谱特征的模型

相比单纯依赖光谱特征的模型，基于空间-光谱特征的模型融合了空间信息与光谱信息，提供了对种子内部结构更为全面的描述。在花生种子的含油率预测任务中，种子内脂肪的空间分布通常呈现局部不均匀性，单纯依赖光谱特征难以有效捕捉这些微小但关键的差异。为了解决这一问题，3D-CNN 模型通过引入深度网络架构，能够在光谱信息的基础上进一步提取空间信息，并实现光谱和空间特征的联合建模。此外，通道注意力机制的引入使得模型能够在特征提取过程中自动识别并强化重要通道，抑制冗余或无关特征，从而提升对复杂结构的学习能力，显著提高了含油率预测的精度。

3.3 局限性与展望

本研究基于 3D-CNN 构建的花生种子含油率预测模型，虽在所选数据集上取得了一定成果，但仍存在一些需要进一步解决的局限性。首先，数据集的样本量相对有限，尤其在极端含油率样本的分布上欠缺充分代表性，这可能导致模型在预测边缘值时出现一定的不稳定性。为提高模型的鲁棒性，后续研究应进一步扩充数据量，并注重收集来自不同生长环境、品种和地区的样本，以便更好地刻画油脂含量的复杂分布特征。

其次，当前的 3D-CNN 模型虽然在训练集和测试集上表现优异，但其在跨地区数据上的泛化能力尚未得到充分验证。因此，建议后续工作在多中心、多区域的真实场景下对模型进行验证和调试，确保模型在实际应用中的稳定性与可靠性。

此外，3D-CNN 在特征提取方面显示出较大优势，但其高计算复杂度也不容忽视，这对硬件设备提出了较高要求。未来研究可从以下几方面开展：一是通过模型轻量化设计和高效网络结构优化，在保证预测准确率的前提下降低计算资源消耗；二是尝试引入自监督学习、迁移学习等先进方法，以在小样本或数据稀缺的情况下进一步提升模型性能。

总之，尽管本研究已在花生种子含油率预测上取得初步成功，但上述局限性表明，模型在实际应用推广前仍需数据多样性、跨域适应性以及计算效率等方面做出更多努力。未来的工作应进一步探索模型结构的优化和新技术的融合，以期构建一个更具泛化能力和应用前景的预测系统。

4 结 论

本研究建立了一种基于加权池化和通道注意力机制的三维卷积神经网络（3D weighted pooling and channel attention convolutional neural network, 3D-WPCA-CNN）模型，用于预测单粒花生种子的含油率。该模型专门针

对花生种子的高光谱图像，充分融合光谱信息与空间结构特征，从而提升预测精度。试验结果表明，与传统的 1D-CNN 以及不包含注意力机制的 3D-CNN 模型相比，本研究提出的 3D-WPCA-CNN 模型在含油率预测任务中表现更优（ $R^2=0.8092$ ， $RMSE=1.713\%$ ）。这一优势主要归因于 3D-WPCA-CNN 模型在光谱与空间信息融合方面的有效性，表明其在作物种子成分预测中的应用潜力。此外，该模型采用“端到端”结构，简化了数据预处理流程，减少了复杂的前期操作，提高了实际应用的可行性。在农业育种、品质控制等领域，该方法有望提供更高效率、精准的技术支持。未来研究可进一步探索 3D-CNN 模型在其他作物种子成分预测任务中的适用性，以拓展其在农业生产中的应用价值。本研究结果验证了基于深度学习的高光谱图像分析方法在农业科学中的广阔前景，尤其在作物育种、品质评估及精准农业管理等方面具有重要的应用价值。

【参 考 文 献】

- [1] BERTIOLI D J, ABERNATHY B, SEIJO G, et al. Evaluating two different models of peanut's origin[J]. *Nature Genetics*, 2020, 52(6): 557-559.
- [2] KUNTA S, PARIMI P, LEVY Y, et al. A first insight into the genetics of maturity trait in Runner $\times$ Virginia types peanut background[J]. *Scientific Reports*, 2022, 12(1): 15267.
- [3] CHEN T, LI G, ZHANG H. Editorial: Advances in peanut research[J]. *Frontiers in Plant Science*, 2023, 14: 1180009.
- [4] JIN H, MA Y, LI L, et al. Rapid and non-destructive determination of oil content of peanut (*Arachis hypogaea* L.) using hyperspectral imaging analysis[J]. *Food Analytical Methods*, 2016, 9(7): 2060-2067.
- [5] HARUNA S A, LI H, ZAREEF M, et al. Application of NIR spectroscopy for rapid quantification of acid and peroxide in crude peanut oil coupled multivariate analysis[J]. *Spectrochimica Acta Part A: Molecular and Biomolecular Spectroscopy*, 2022, 267: 120624.
- [6] YU H, LIU H, ERASMUS S W, et al. Rapid high-throughput determination of major components and amino acids in a single peanut kernel based on portable near-infrared spectroscopy combined with chemometrics[J]. *Industrial Crops and Products*, 2020, 158: 112956.
- [7] 段洁利, 张汉尧, 付函, 等. 基于高光谱成像技术的青香蕉碰撞损伤检测[J]. *农业工程学报*, 2023, 39(7): 176-184. DUAN Jieli, ZHANG Hanyao, FU Han, et al. Collision damage detection of green bananas using hyperspectral imaging[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2023, 39(7): 176-184. (in Chinese with English abstract)
- [8] 帅爽, 张志, 张天, 等. 特征优化结合随机森林算法的干旱区植被高光谱遥感分类方法[J]. *农业工程学报*, 2023, 39(9): 287-293. SHUAI Shuang, ZHANG Zhi, ZHANG Tian, et al. Hyperspectral image classification method for dryland vegetation by combining feature optimization and random forest algorithm[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2023, 39(9): 287-293. (in Chinese with English abstract)
- [9] 白宗秀, 朱荣光, 王世昌, 等. 高光谱图像结合特征变量筛选定量检测羊肉中狐狸肉掺假[J]. *农业工程学报*, 2021, 37(17): 276-284. BAI Zongxiu, ZHU Rongguang, WANG Shichang, et al. Quantitative detection of fox meat adulteration in mutton by hyper spectral imaging combined with characteristic variables screening[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2021, 37(17): 276-284. (in Chinese with English abstract)

- [10] 江凯伦, 安吉庆, 赵雨薇, 等. 采用 RNCA-PSO-ELM 的水稻叶绿素光谱特征分析与反演[J]. *农业工程学报*, 2022, 38(8): 178-186.
JIANG Kailun, AN Jiqing, ZHAO Yuwei, et al. Analysis and inversion of rice chlorophyll spectral characteristics using RNCA-PSO-ELM[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2022, 38(8): 178-186. (in Chinese with English abstract)
- [11] ZHANG L, AN D, WEI Y, et al. Prediction of oil content in single maize kernel based on hyperspectral imaging and attention convolution neural network[J]. *Food Chemistry*, 2022, 395: 133563.
- [12] CAPORASO N, WHITWORTH M B, FISK I D. Protein content prediction in single wheat kernels using hyperspectral imaging[J]. *Food Chemistry*, 2018, 240: 32-42.
- [13] MA J, ZHENG B, HE Y. Applications of a hyperspectral imaging system used to estimate wheat grain protein: A review[J]. *Frontiers in Plant Science*, 2022, 13: 837200.
- [14] SUN J, WANG G, ZHANG H, et al. Detection of fat content in peanut kernels based on chemometrics and hyperspectral imaging technology[J]. *Infrared Physics & Technology*, 2020, 105: 103226.
- [15] ZOU S, TSENG Y C, ZARE A, et al. Peanut maturity classification using hyperspectral imagery[J]. *Biosystems Engineering*, 2019, 188: 165-177.
- [16] ZOU Z, CHEN J, ZHOU M, et al. Prediction of peanut seed vigor based on hyperspectral images[J]. *Food Science and Technology*, 2022, 42: e32822.
- [17] HUANG M, TANG J, YANG B, et al. Classification of maize seeds of different years based on hyperspectral imaging and model updating[J]. *Computers and Electronics in Agriculture*, 2016, 122: 139-145.
- [18] ZOU Z, CHEN J, ZHOU M, et al. Identification of peanut storage period based on hyperspectral imaging technology[J]. *Food Science and Technology*, 2022, 42: e65822.
- [19] QIAO M, XU Y, XIA G, et al. Determination of hardness for maize kernels based on hyperspectral imaging[J]. *Food Chemistry*, 2022, 366: 130559.
- [20] SONG A, WANG C, WEN W, et al. Predicting the oil content of individual corn kernels combining NIR-HSI and multi-stage parameter optimization techniques[J]. *Food Chemistry*, 2024, 461: 140932.
- [21] 张通, 金秀, 饶元, 等. 基于无人机多光谱的大豆旗叶光合作用量子产量反演方法[J]. *农业工程学报*, 2022, 38(13): 150-157.
ZHANG Tong, JIN Xiu, RAO Yuan, et al. Inversing photosynthesis quantum yield of the soybean flag leaf using a UAV-carrying multispectral camera[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2022, 38(13): 150-157. (in Chinese with English abstract)
- [22] 张琦, 饶博涵, 范国元, 等. 基于傅里叶变换红外光谱快速检测新疆干红葡萄酒中的多糖类物质[J]. *农业工程学报*, 2025, 41(5): 306-314.
ZHANG Qi, RAO Bohan, FAN Guoyuan, et al. Rapid identification of polysaccharides in Xinjiang dry red wines based on Fourier transform infrared spectroscopy[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2025, 41(5): 306-314. (in Chinese with English abstract)
- [23] 周鑫, 王坚, 赵春江, 等. 基于高光谱深度特征的油菜叶片锌含量检测[J]. *农业工程学报*, 2024, 40(19): 262-271.
ZHOU Xin, WANG Jian, ZHAO Chunjiang, et al. Non-destructive determination of zinc content in oilseed rape leaves based on hyperspectral depth characteristics[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2024, 40(19): 262-271. (in Chinese with English abstract)
- [24] 李国厚, 李泽旭, 金松林, 等. 混合卷积神经网络用于高光谱小麦品种鉴别[J]. *光谱学与光谱分析*, 2024, 44(3): 807-813.
LI Guohou, LI Zexu, JIN Songlin, et al. Mix convolutional neural networks for hyperspectral wheat variety discrimination[J]. *Spectroscopy and Spectral Analysis*, 2024, 44(3): 807-813. (in Chinese with English abstract)
- [25] TU K, WEN S, CHENG Y, et al. A model for genuineness detection in genetically and phenotypically similar maize variety seeds based on hyperspectral imaging and machine learning[J]. *Plant Methods*, 2022, 18(1): 81.
- [26] 刘玉娟, 刘颜达, 闫振, 等. 注意力机制的混合卷积高光谱图像分类方法[J]. *光谱学与光谱分析*, 2024, 44(10): 2916-2922.
LIU Yujuan, LIU Yanda, YAN Zhen, et al. Classification of Hybrid Convolution Hyperspectral Images Based on Attention Mechanism[J]. *Spectroscopy and Spectral Analysis*, 2024, 44(10): 2916-2922. (in Chinese with English abstract)
- [27] LONG Y, HUANG W, WANG Q, et al. Integration of textural and spectral features of Raman hyperspectral imaging for quantitative determination of a single maize kernel mildew coupled with chemometrics[J]. *Food Chemistry*, 2022, 372: 131246.
- [28] HAN Z, GAO J. Pixel-level aflatoxin detecting based on deep learning and hyperspectral imaging[J]. *Computers and Electronics in Agriculture*, 2019, 164: 104888.
- [29] ZOU Z, CHEN J, WU W, et al. Detection of peanut seed vigor based on hyperspectral imaging and chemometrics[J]. *Frontiers in Plant Science*, 2023, 14: 1127108.
- [30] HE K, TIAN J, XIA Y, et al. Detection of the amylose and amylopectin contents of rice by hyperspectral imaging combined with a CNN-AdaBoost model[J]. *Journal of Food Composition and Analysis*, 2025, 142: 107468.
- [31] 鞠皓, 姜洪喆, 周宏平. 油料作物与产品品质近红外光谱及高光谱成像检测研究进展[J]. *中国粮油学报*, 2022, 37(9): 303-310.
JU Hao, JIANG Hongzhe, ZHOU Hongping. Research progress of near infrared spectroscopy and hyperspectral imaging in determination on quality of oilseed and its products[J]. *Journal of the Chinese Cereals and Oils Association*, 2022, 37(9): 303-310. (in Chinese with English abstract)
- [32] 朱昊宇, 王俊杰, 杨一, 等. 基于近红外高光谱图像的花生内部霉变快速判别方法研究[J]. *食品安全质量检测学报*, 2024, 15(1): 85-91.
ZHU Haoyu, WANG Junjie, YANG Yi, et al. Research on rapid discrimination for internal mold detection in peanuts based on near-infrared hyperspectral image[J]. *Journal of Food Safety & Quality*, 2024, 15(1): 85-91. (in Chinese with English abstract)
- [33] FENG H, CHEN Y, SONG J, et al. Maturity classification of rapeseed using hyperspectral image combined with machine learning[J]. *Plant Phenomics*, 2024, 6: 0139.
- [34] LIU N, HUANG L, CHEN W, et al. Dissection of the genetic basis of oil content in Chinese peanut cultivars through association mapping[J]. *BMC Genetics*, 2020, 21(1): 60.
- [35] NAYAK S N, HEBBAL V, BHARATI P, et al. Profiling of nutraceuticals and proximates in peanut genotypes differing for seed coat color and seed size[J]. *Frontiers in Nutrition*, 2020, 7: 45.
- [36] LI W, CHEN H, LIU Q, et al. Attention mechanism and depthwise separable convolution aided 3D-CNN for hyperspectral remote sensing image classification[J]. *Remote Sensing*, 2022, 14(9): 2215.
- [37] SONG B, WU Z, XU Y, et al. 3D-CNN-NF: Few-Shot hyperspectral image change detection based on 3-D convolution neural network and normalizing flow[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2024, 62: 1-15.
- [38] 黄敏, 夏超, 朱启兵, 等. 融合高光谱图像技术与 MS-3D-CNN 的小麦种子品种识别模型[J]. *农业工程学报*, 2021, 37(18): 153-160.
HUANG Min, XIA Chao, ZHU Qibing, et al. Recognizing wheat seed varieties using hyperspectral imaging technology combined with multi-scale 3D convolution neural network[J].

- Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2021, 37(18): 153-160. (in Chinese with English abstract)
- [39] ZHANG L, WANG Y, WEI Y, et al. Near-infrared hyperspectral imaging technology combined with deep convolutional generative adversarial network to predict oil content of single maize kernel[J]. *Food Chemistry*, 2022, 370: 131047.
- [40] HORN P J, NEOGI P, TOMBOKAN X, et al. Simultaneous quantification of oil and protein in cottonseed by low-field time-domain nuclear magnetic resonance[J]. *Journal of the American Oil Chemists' Society*, 2011, 88(10): 1521-1529.
- [41] 陈睿华, 王怡婧, 张俊华, 等. 利用正交信号校正消除水分影响的银川平原土壤盐分高光谱反演[J]. *农业工程学报*, 2023, 39(19): 122-130.
- CHEN Ruihua, WANG Yijing, ZHANG Junhua, et al. Hyperspectral inversion of soil salinity after correcting moisture effect in Yinchuan Plain using orthogonal signals[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2023, 39(19): 122-130. (in Chinese with English abstract)
- [42] 田安红, 李智缘, 付承彪, 等. 云南墨江矿区周边山地农田土壤重金属的高光谱反演[J]. *农业工程学报*, 2025, 41(5): 191-200.
- TIAN Anhong, LI Zhiyuan, FU Chengbiao, et al. Hyperspectral inversion of soil heavy metals in mountain farmland around Mojiang Mining Areas in Yunnan, China[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2025, 41(5): 191-200. (in Chinese with English abstract)
- [43] 王海峰, 张智韬, KARNIELI A, 等. 基于灰度关联-岭回归的荒漠土壤有机质含量高光谱估算[J]. *农业工程学报*, 2018, 34(14): 124-131.
- WANG Haifeng, ZHANG Zhitao, KARNIELI A, et al. Hyperspectral estimation of desert soil organic matter content based on gray correlation-ridge regression model[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2018, 34(14): 124-131. (in Chinese with English abstract)
- [44] 冯惠芬, 李映雪, 吴芳, 等. 机器学习结合高光谱植被指数与 SPAD 值估算冬小麦氮含量[J]. *农业工程学报*, 2024, 40(1): 227-237.
- FENG Huifen, LI Yingxue, WU Fang, et al. Estimating winter wheat nitrogen content using SPAD and hyperspectral vegetation indices with machine learning[J]. *Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE)*, 2024, 40(1): 227-237. (in Chinese with English abstract)

Evaluation of peanut kernel oil content using 3D-WPCA-CNN based on hyperspectral imaging

SONG Anran^{1,2,3}, GUO Xinyu^{1,3*}, GU Shenghao^{1,3}, CHEN Xiaoqian^{1,3}, WANG Baiyan^{1,3}

(1. Information Technology Research Center, Beijing Academy of Agriculture and Forestry Sciences, Beijing 100097, China;

2. School of Chemistry and Biological Engineering, University of Science and Technology Beijing, Beijing 100083, China;

3. National Engineering Research Center for Information Technology in Agriculture, Beijing 100097, China)

Abstract: The rapid, non-destructive, and precise prediction of oil content in peanut seeds is of great significance for accelerating the breeding process and meeting the demands of the food industry. This study proposes a novel 3D weighted pooling and channel attention convolutional neural network (3D-WPCA-CNN) model to enhance the accuracy of oil content prediction. The model integrates two key components: a weighted average pooling layer and a channel attention mechanism, both designed to optimize feature extraction and information weighting in high-dimensional data. The weighted average pooling layer is developed to enhance the extraction of critical features while reducing interference from irrelevant or noisy information. Unlike conventional pooling methods, such as max pooling or average pooling, which treat all spatial features equally, this layer introduces learnable weight matrices that dynamically adjust based on feature importance. During the training process, these weights are continuously optimized, allowing the model to highlight the most informative spatial and spectral features while suppressing less relevant ones. The pooling operation is implemented using weighted 3D convolution, where each feature channel is assigned an independent weight matrix, ensuring that different spectral channels are processed distinctly. Additionally, the model adopts grouped convolution to maintain independence among channels and improve computational efficiency. The learnable weight parameters are initialized randomly and progressively fine-tuned through backpropagation, enabling the network to adaptively focus on key spectral and spatial information. The channel attention mechanism further enhances the model's feature selection capability by dynamically adjusting the importance of different channels in the hyperspectral image. Traditional convolutional neural networks (CNNs) treat all channels as equally important, which may not be optimal for hyperspectral data, where certain spectral bands carry more relevant information for predicting oil content. To address this, the proposed mechanism first applies global average pooling across the spatial dimensions to extract a channel-wise feature descriptor, summarizing the overall contribution of each channel. This descriptor is then processed through a lightweight fully connected network, which learns to assign importance weights to each channel. The network includes a hidden layer with a ReLU activation function, followed by an output layer with a sigmoid activation function, ensuring that the learned weights are normalized. The attention weights are then applied to reweight the input feature channels, emphasizing high-contribution channels while suppressing redundant or irrelevant ones. This process enables the model to refine its feature representation dynamically, improving its predictive accuracy. To validate the superiority of the proposed approach, the model was compared against a convolutional neural network (CNN) based on mean spectral features. The proposed 3D-CNN model demonstrated higher predictive accuracy ($R^2 = 0.809\ 2$, RMSE = 1.713 1%) compared to the model based on average spectra ($R^2 = 0.698\ 3$, RMSE = 2.183 7%), 3D Average pooling convolutional neural network without Channel Attention ($R^2 = 0.721\ 7$, RMSE = 2.069 3%) and the 3D Weighted pooling convolutional neural network without Channel Attention ($R^2 = 0.738\ 4$, RMSE = 2.005 9%). Furthermore, the RPD of the 3D CNN model was 2.338 9, indicating its reliable performance in predicting oil content. This study provides a novel high-dimensional modeling approach for hyperspectral image-based crop seed composition prediction, offering valuable practical implications for the precise assessment of quality traits in peanuts and other agricultural crops.

Keywords: peanut kernels; hyperspectral images; oil content; channel attention mechanism; 3D convolutional neural network